# Fundamentos de Big Data

**Eduardo Viegas** 



• Qual a mercadoria com a maior quantidade de transações comerciais no Brasil?

Campo	Descrição
País	País envolvido na transação comercial
Ano	Ano em que a transação foi efetuada
Código	Código da mercadoria
Mercadoria	Descrição da mercadoria
Fluxo	Fluxo, e.g. Exportação ou Importação
Valor	Valor em dólares
Peso	Peso da mercadoria
Unidade	Unidade de medida da mercadoria, e.g. Quantidade de itens
Quantidade	Quantidade conforme a unidade especificada da mercadoria
Categoria	Categoria da mercadoria, e.g. Produto Animal

SQL-like

select Mercadoria, COUNT(\*) as quantidade from Tabela where Pais = "Brasil" group by Mercadoria

• Qual a mercadoria com a maior quantidade de transações comerciais no Brasil?

SQL-like

select Mercadoria, COUNT(\*) as quantidade from Tabela where Pais = "Brasil" group by Mercadoria

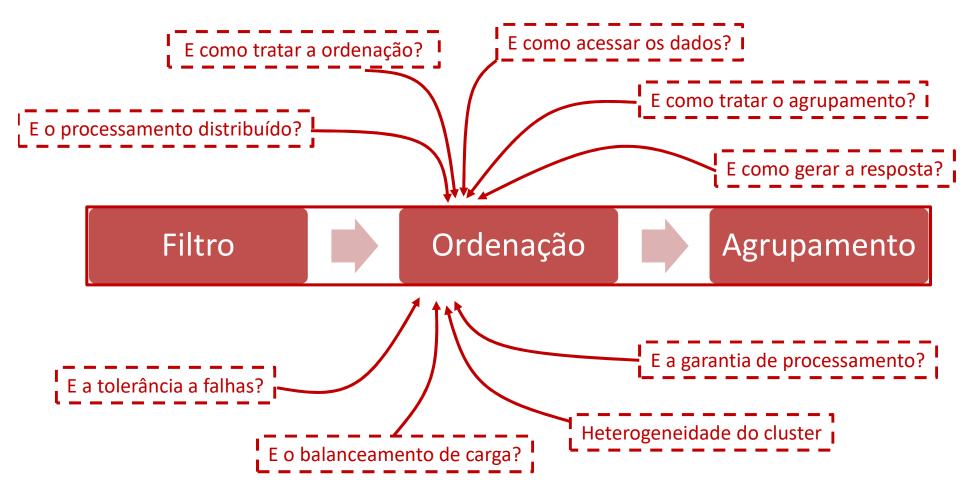
- Etapas
  - Filtro
  - Ordenação
  - Agrupamento

- Suponha que você possui uma base de dados com o seguinte formato
  - 1 TB de dados
  - +1 Bilhão de transações comerciais
  - Dados armazenados no HDFS, mais de 1000 máquinas

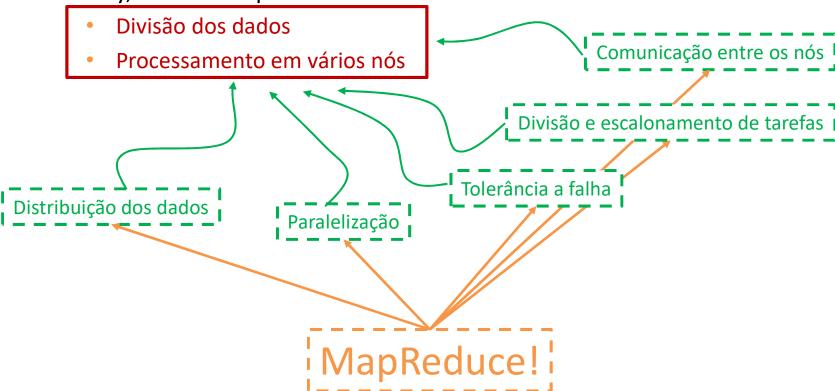
Campo	Descrição
País	País envolvido na transação comercial
Ano	Ano em que a transação foi efetuada
Código	Código da mercadoria
Mercadoria	Descrição da mercadoria
Fluxo	Fluxo, e.g. Exportação ou Importação
Valor	Valor em dólares
Peso	Peso da mercadoria
Unidade	Unidade de medida da mercadoria, e.g. Quantidade de itens
Quantidade	Quantidade conforme a unidade especificada da mercadoria
Categoria	Categoria da mercadoria, e.g. Produto Animal

• Qual a mercadoria com a maior quantidade de transações comerciais no Brasil?

Podemos fazer isso "manualmente"?



- HDFS abstrai a complexidade de armazenamento distribuído de dados
- Okay, mas como processar essa massa de dados armazenada?



- MapReduce é o paradigma precursor de análise de dados em cenários de Big Data
  - Framework para computação distribuída
  - Abstrai os conceitos de
    - Paralelização
    - Distribuição dos dados
    - Balanceamento de carga
    - Tolerância a falha
    - Processamento distribuído
  - Provém uma camada de abstração para o programador
  - Executa as tarefas sobre os arquivos do HDFS
  - Distribui o processamento no cluster
  - Leva a computação para os dados

#### MapReduce – Modelo

 Programador deve apenas especificar as funções de Map e Reduce, o framework se encarrega do resto!

#### Map

Aplica uma função f para cada elemento de uma lista, retornando uma nova lista Ex.

Quadrado: map [1 2 3 4] -> [1 4 9 16] Filtro > 2: map [1 2 1 4 6] -> [4 6]

Filtro: map ["1;2.2;PUCPR" "1;4;Eduardo"] -> ["PUCPR" "Eduardo"]

#### Reduce

Combina os elementos de uma lista, através de uma função f para gerar um novo valor Ex.

Soma: reduce [1 4 9 16] -> [30] Conta: reduce [1 2 1 4 6] -> [5]

Ocorrencia: reduce ["PUCPR" "Eduardo" "Eduardo"] -> ["PUCPR:1" "Eduardo:2"]

## MapReduce – Modelo

- MapReduce não altera os dados de entrada!
  - Apenas gera novos dados
- Tarefa MapReduce consiste basicamente de mapper e reducer

#### Mapper

Recebe os dados de entrada para análise

Normalmente é utilizado para filtro dos campos de interesse Gera como saída um ou mais pares de chave/valor para cada entrada

Saída

(chave, valor)

#### Shuffle/Sort

Efetuado pelo framework Transparente ao programador Agrupa a chave aos valores!

#### Reducer

Recebe os dados do mapper agrupados por

#### Entrada

(chave, (valor1, valor2, ...))

Executado após a função de map Reduz a entrada a um ou mais pares de chave/valor

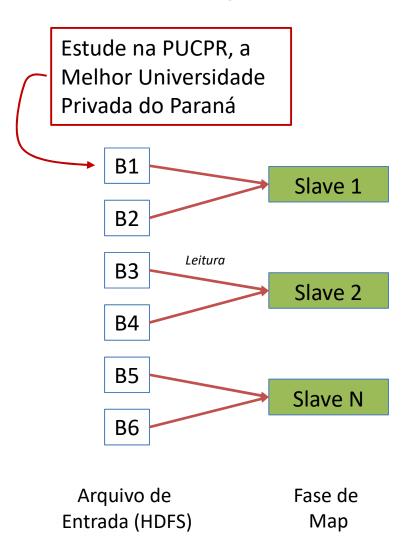
#### MapReduce

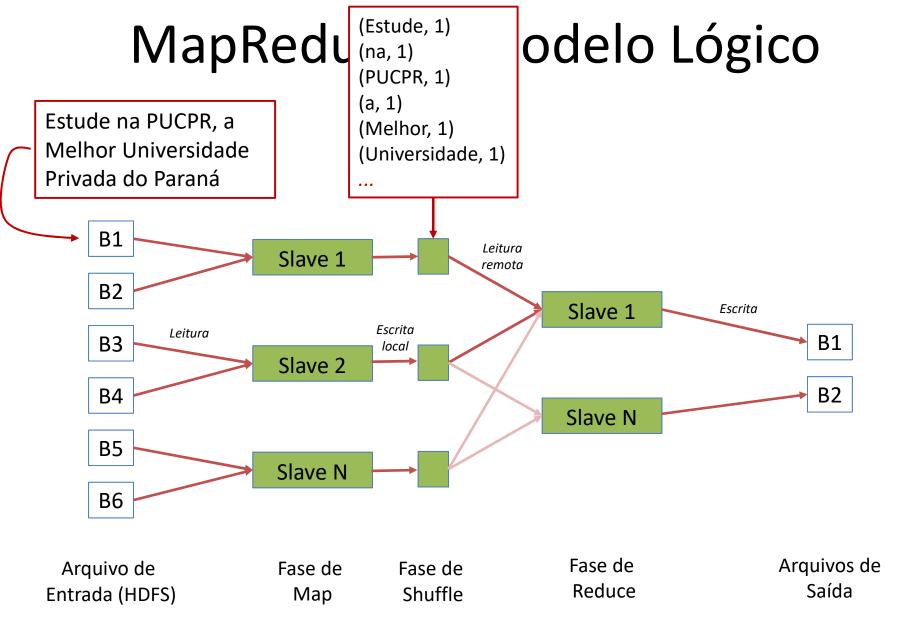
Considere um arquivo com o seguinte formato

```
Afghanistan;2016;010410;Sheep, live;Export;6088;2339;Number of items;51;01_live_animals
Afghanistan;2016;010420;Goats, live;Export;3958;984;Number of items;53;01_live_animals
Afghanistan;2008;010210;Bovine animals, live pure-bred breeding;Import;1026804;272;Number of items;3769;01_live_animals
Albania;2016;010290;Bovine animals, live, except pure-bred breeding;Import;2414533;1114023;Number of items;6853;01_live_animals
Albania;2016;010392;Swine, live except pure-bred breeding > 50 kg;Import;14265937;9484953;Number of items;96040;01_live_animals
Albania;2016;010511;Fowls, live domestic < 185 grams;Import;2671732;254652;Number of items;5629138;01_live_animals
Albania;2016;010511;Fowls, live domestic < 185 grams;Export;87581;5320;Number of items;115180;01_live_animals
Albania;2016;010591;Fowls, live domestic > 185 grams;Import;2421513;1926850;Number of items;1006990;01_live_animals
```

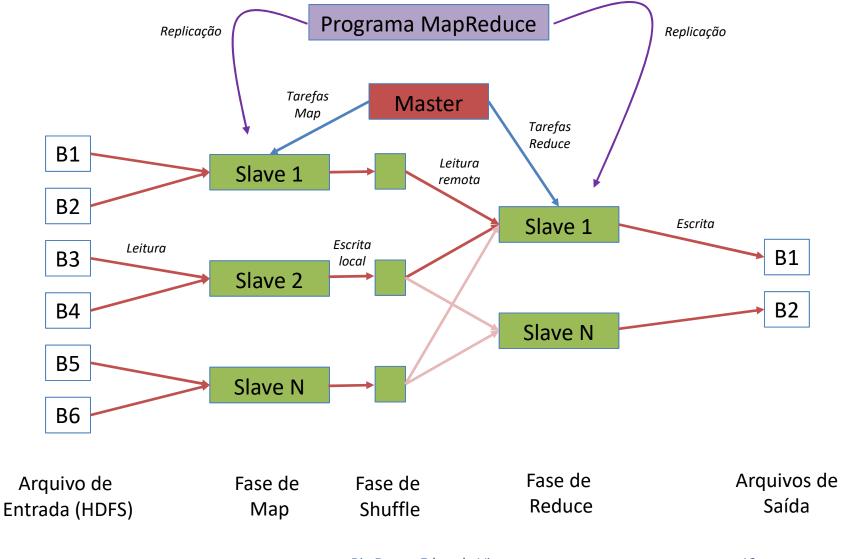
- Como podemos estruturar uma função MapReduce para determinar:
  - Qual a quantidade de transações comerciais por pais?
  - Qual a quantidade de transações comerciais do tipo Sheep por pais?
  - Qual o ano que o Brasil realizou mais operações comerciais?

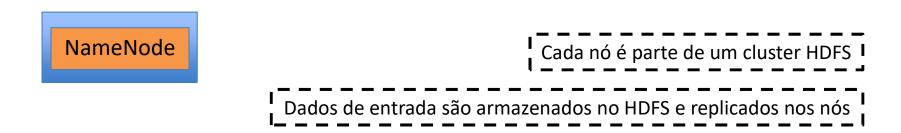
# MapReduce – Modelo Lógico

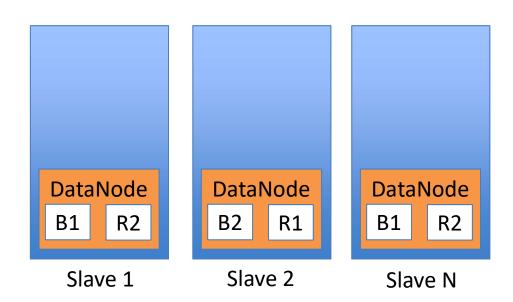


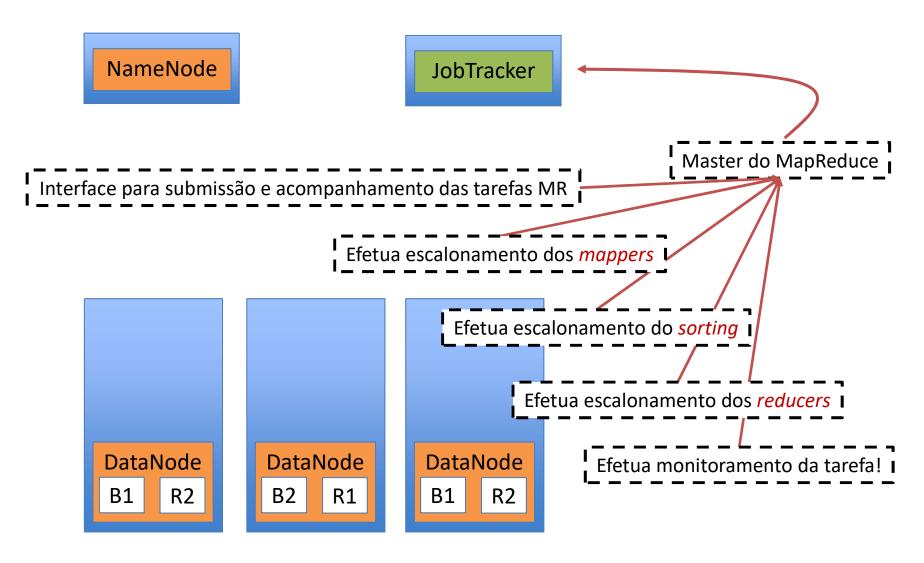


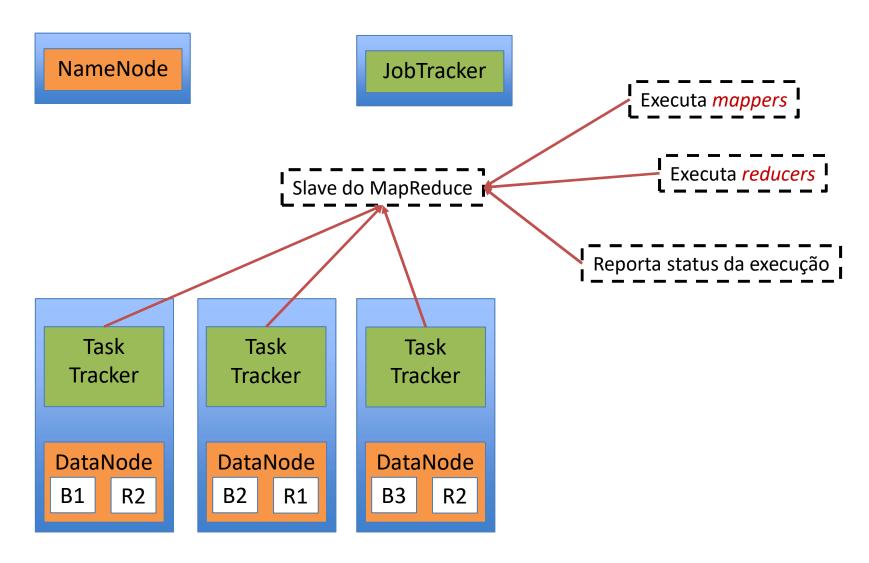
# MapReduce – Modelo Lógico



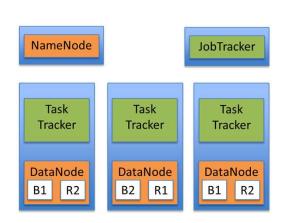








- Tarefas de Map são executadas em paralelo
  - Geram resultados intermediários de chave/valor
- Fase de shuffle e sort
  - Saída da função de map é particionada de acordo com a quantidade de reducers
  - Particionamento garante que o valor com a mesma chave é enviado a mesma partição
  - A partição é sorteada pela chave para agrupar os valores de acordo
- Tarefas de reduce
  - Cada partição é enviada a um reducer
  - Reducers são executados em paralelo
  - Framework garante que o mesmo reducer irá receber os valores da mesma chave



#### MapReduce - Vantagens

#### Principio da localidade

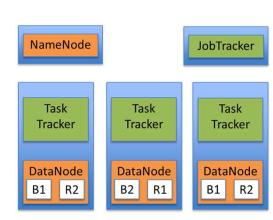
- Framework evita mover os dados pela rede
- TaskTracker é executado geralmente no mesmo nó do DataNode, bloco é lido localmente!
- JobTracker divide as tarefas baseado na localização dos dados

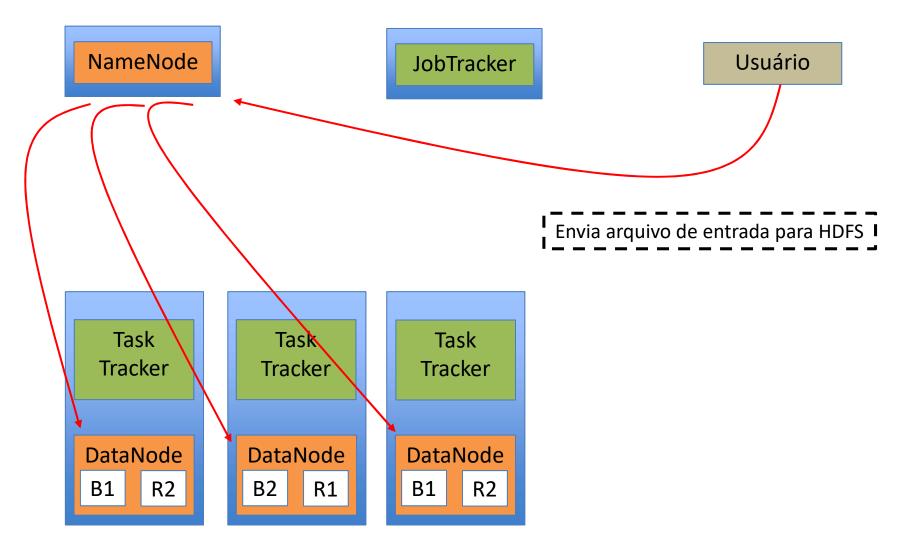
#### Paralelismo

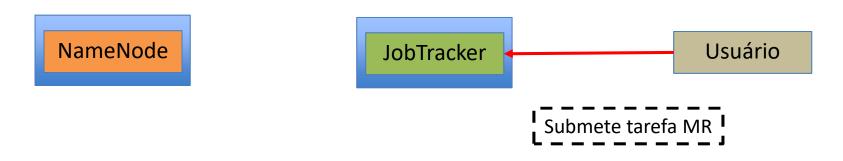
- Função de map é executada paralelamente sobre cada bloco
- Função de reduce é executada em paralelo sobre chaves diferentes
- Função reduce é executada apenas após a execução da função map

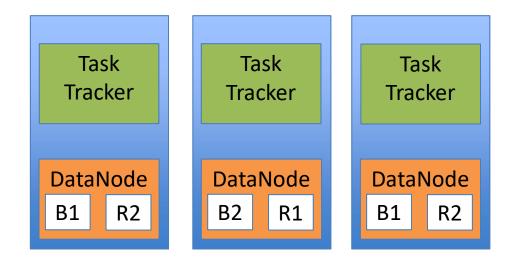
#### Tolerância a falha

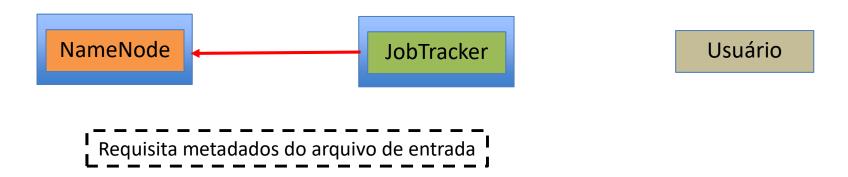
- JobTracker monitora TaskTrackers
- Falhas são tratadas pela reexecução sobre o bloco!
- Se um nó falha, outro nó com as replicas dos blocos reexecuta a tarefa

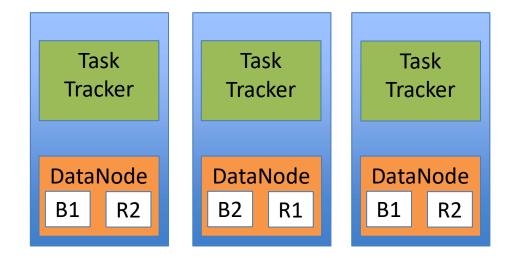


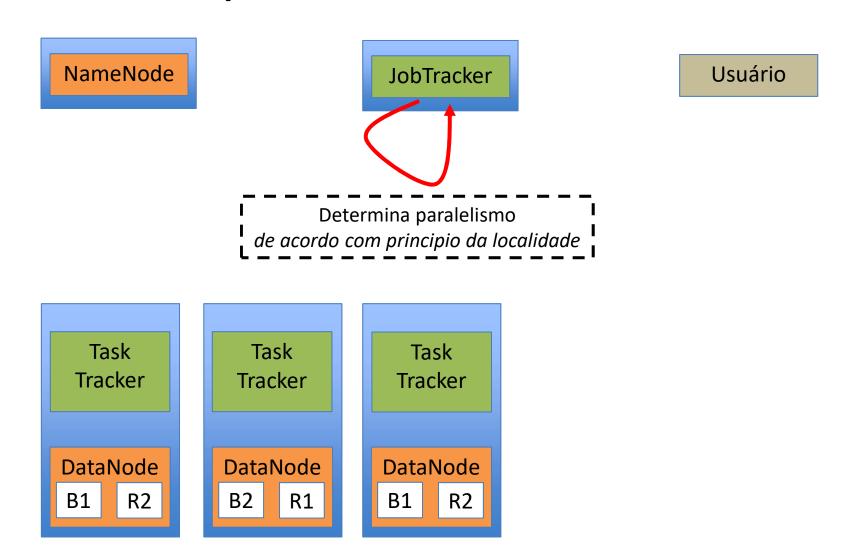


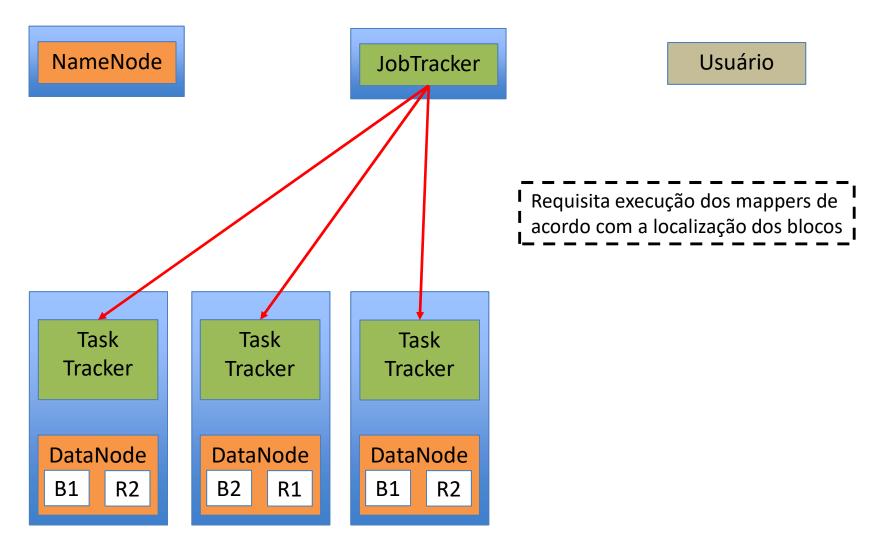


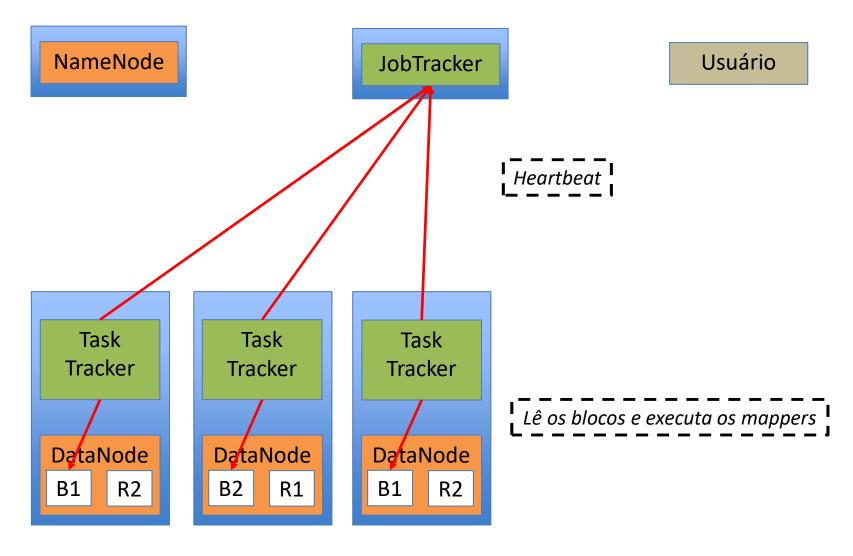


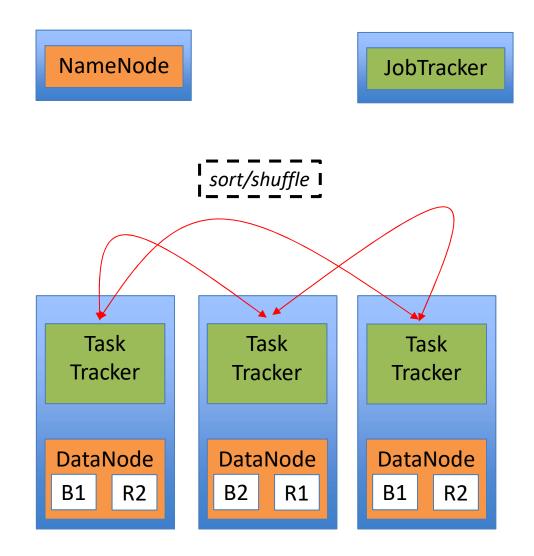




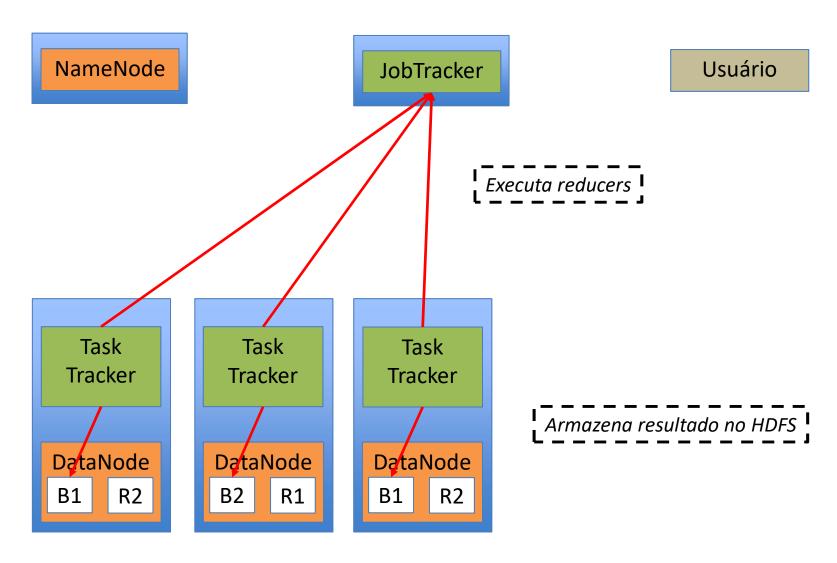






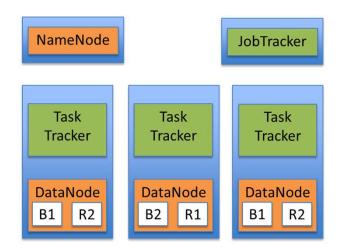


Usuário



#### MapReduce - Passos

- Para executarmos uma tarefa MapReduce em nosso cluster
  - Escrita da função de mapper
  - Escrita da função de reducer
  - Teste local
  - Cópia do código para o jobtracker
  - Execução no cluster



# MapReduce - Atividade

Campo	Descrição
País	País envolvido na transação comercial
Ano	Ano em que a transação foi efetuada
Código	Código da mercadoria
Mercadoria	Descrição da mercadoria
Fluxo	Fluxo, e.g. Exportação ou Importação
Valor	Valor em dólares
Peso	Peso da mercadoria
Unidade	Unidade de medida da mercadoria, e.g. Quantidade de itens
Quantidade	Quantidade conforme a unidade especificada da mercadoria
Categoria	Categoria da mercadoria, e.g. Produto Animal

